

# 클린업 3주차

5팀 시계열자료분석팀

염예빈  
한유진  
이재현  
박세령  
이정우

# INDEX

---

1. 2주차 복습

2. ARIMA

3. SARIMA

4. ARFIMA

5. ARCH/GARCH

# 1

## 2주차 복습

ACF/PACF

AR/MA/ARMA

모형의 적합

## 자기상관계수(Auto-Correlation Function)

$$\rho(k) = \text{Corr}(X_t, X_{t+k})$$

$$= \frac{\text{Cov}(X_t, X_{t+k})}{\sqrt{\text{Var}(X_t)}\sqrt{\text{Var}(X_{t+k})}} = \frac{\gamma(k)}{\gamma(0)},$$

이때  $\gamma_0 = \text{Var}(X_t) = E[(X_t - \mu)^2]$

## 표본자기상관함수(SACF)

$$\hat{\rho}_{(k)} = \frac{\hat{\gamma}_{(k)}}{\hat{\gamma}_{(0)}}$$

$$\rho(k) = \text{Corr}(X_t, X_{t+k})$$

자기상관함수(ACF)는  
시차 k에서 자기상관관계가  
존재하는지 나타내는 척도

서로 다른 두 시점의  
상호 연관관계를 나타냄

ACF/PACF

AR/MA/ARMA

모형의 적합

PACF(Partial Autocorrelation Function) : 편자기상관함수

## “ PACF

:두 변수를 제외한 **모든 변수의 영향을 제거**한 상태에서,  
두 변수사이의 **순수한 상호연관관계**



ACF/PACF

AR/MA/ARMA

모형의 적합

## AR 모형

자기 회귀 모형  
= **A**uto **R**egressive Model

자기 자신을 과거 시점에 회귀

현재의 자료 ← 설명0 과거의 자료  
                  ← 설명X           +  
  오차항

ACF/PACF

AR/MA/ARMA

모형의 적합

## MA 모형

이동 평균 모형  
= Moving Average Model

현재의 관측값이 현재와 과거의 설명해 주지 못하는 부분(오차)의  
선형결합으로 표시되는 모형

현재의 자료

선형결합과거의 자료의  
오차

ACF/PACF

AR/MA/ARMA

모형의 적합

## ARMA 모형

자기 회귀 이동 평균 모형  
= **A**uto **R**egressive **M**oving **A**verage Model

AR 모형의 차수  $p$ , MA 모형의 차수  $q$ 인 모형

AR과 MA를 동시에 사용한다면 추정해야 할 모수의 개수를 줄일 수 있다!



ACF/PACF

AR/MA/ARMA

모형의 적합

## 정리

정상성, 인과성

가역성

모두 만족 해야해!!

AR

+

MA

=

ARMA

 $\Phi(B) = 0$ 의 근의 절댓값  $> 1$  $\theta(B) = 0$ 의 근의 절댓값  $> 1$

ACF/PACF

AR/MA/ARMA

모형의 적합

## 모형의 ACF와 PACF 패턴

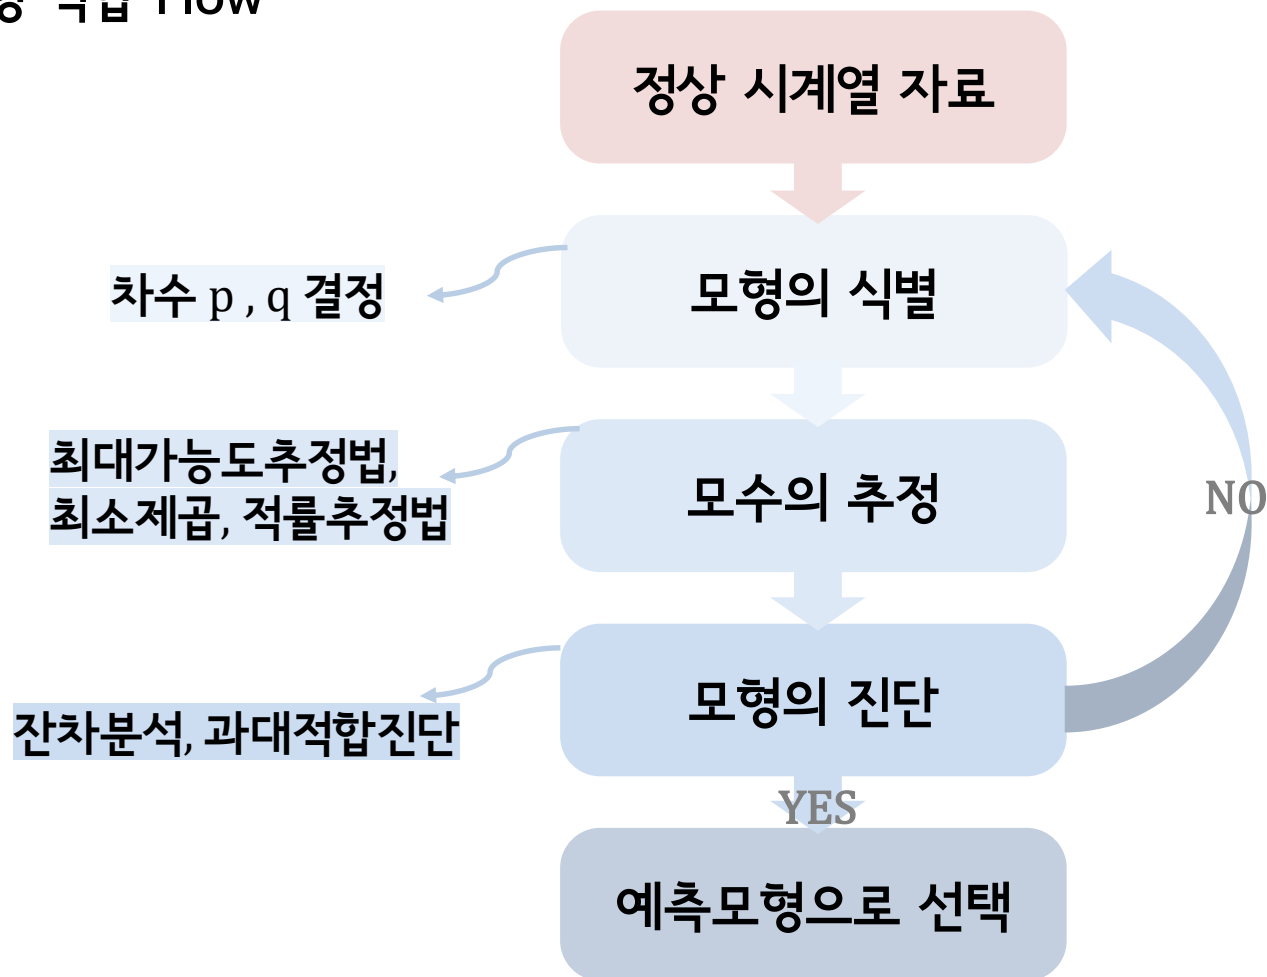
	AR( <b>p</b> )	MA( <b>q</b> )	ARMA( <b>p</b> , <b>q</b> )
ACF	지수적으로 감소	$q+1$ 차부터 절단	$q+1$ 시점부터 지수적으로 감소
PACF	$p+1$ 차부터 절단	지수적으로 감소	$p+1$ 시점부터 지수적으로 감소

ACF/PACF

AR/MA/ARMA

모형의 적합

## 모형 적합 Flow



# 2

ARIMA

## ARIMA

## Auto-Regressive Integrated Moving Average

정상화 방법 중 차분 후

 $ARMA(p,q)$  $=$  $ARIMA(p,d,q)$ 

즉, 차분과정까지 포함한 모델!!

Trend(추세) +  $ARMA(p,q)$  형태가 있을 때 사용!



ARIMA에서 I는 무슨 뜻인가요?

**I는 누적(integrated)의 의미**

$$\phi(B)(1 - B)^d Z_t = \theta(B)\varepsilon_t$$

$$\begin{aligned} & (1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p)(1 - B)^d Z_t \\ &= (1 + \theta_1 B + \theta_2 B^2 + \dots + \theta_q B^q)\varepsilon_t \\ & \phi_B(1 - B)Z_t = \phi(B)\varepsilon_t \text{에서} \end{aligned}$$

$$W_t = (1 - B)Z_t \text{이라고 한다면, } W_t = Z_t - Z_{t-1}$$

$$Z_t = W_t + Z_{t-1} = W_t + (W_{t-1} + Z_{t-2}) = W_t + W_{t-1} + (W_{t-2} + Z_{t-3})$$

$$= \dots = Z_0 + \sum_{j=1}^t W_j \quad \therefore Z_t \text{부분은 } W_t \text{의 누적합이 된다.}$$

## ARIMA의 표현

ARIMA(p, d, q) :

$$\phi(B)(1 - B)^d(Z_t - \mu) = \theta(B)\varepsilon_t$$

$$\begin{aligned} & (1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p)(1 - B)^d Z_t \\ &= (1 + \theta_1 B + \theta_2 B^2 + \dots + \theta_q B^q)\varepsilon_t \end{aligned}$$

## ARIMA의 표현

## ARIMA(p, d, q)

ARIMA(p, d, q) :

**p** : AR의 차수  
 $\phi(B)(1-B)^d(Z_t - \mu) = \theta(B)\varepsilon_t$

**d** : 차분을 몇 번 했는가!  
 $(1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p)(1 - B)^d Z_t$

**q** : MA의 차수  
 $= (1 + \theta_1 B + \theta_2 B^2 + \dots + \theta_q B^q)\varepsilon_t$

cf) ARIMA(p, 0, q) = ARMA(p, q)

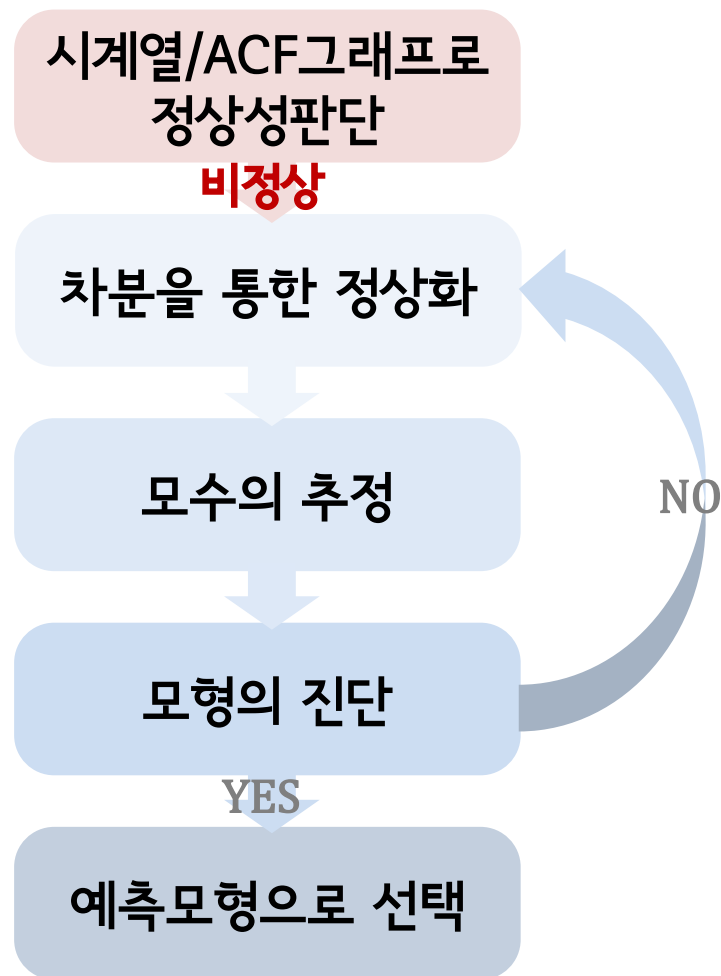


## ARIMA

## ARIMA의 표현

## ARIMA 모형의 적합

## ARIMA 모형의 적합



ARIMA


ARIMA의 표현

ARIMA 모형의 적합

ARIMA 모형의 적합

시계열/ACF그래프로  
정상성판단

시계열 plot을 보았을 때, 추세가 존재하는 것 처럼 보임!



ARIMA


ARIMA의 표현

ARIMA 모형의 적합

ARIMA 모형의 적합

시계열/ACF그래프로  
정상성판단

추세가 존재한다면, ACF가 천천히 감소



추세가 존재하는  
비정상 시계열이네??



ARIMA 모형이 필요해 보임!!



## ARIMA 모형의 적합

일반적으로  $d=1$  or  $2$  낮은 차수를 많이 사용.  
**과대 차분** 위험때문!!!

차분을 통한 정상화

차분한 시계열이  $ARMA(p,q)$  과정을 따르는지 살펴보고  
 **$ARIMA(p,d,q)$ 에 적합!**

예측모형으로 선택

## ARIMA 모형의 적합

일반적으로  $d=1$  or  $2$  낮은 차수를 많이 사용.

과대 차분 위험때문!!!

**과대 차분이란?**

차분을 통한 정상화

이미 정상화가 된 경우에도

차분을 시도 하는 것!

차분한 시계열이  $ARMA(p,q)$  과정을 따르는지 살펴보고  
 $ARIMA(p,d,q)$ 에 적합!

ARIMA

ARIMA의 표현

ARIMA 모형의 적합

ARIMA 모형의 적합

적합 후에는?

한 번  
비정상

차분을 통한 정상화

2주차 클린업을 참고해주세요!

모수의 추정

모형의 진단

YES

예측모형으로 선택

NO

3

SARIMA



계절성을 가지는 시계열

순수 SARIMA

승법 SARIMA

계절성을 가지는 시계열

$$Y_t = S_t + I_t$$

## 1. 결정적 계절성

항상 식을 통해 도출되는  $S_t$

$$S_t = a_0 + \sum_{j=1}^k a_j \cos(\lambda_j t) + b_j \sin(\lambda_j t)$$

회귀, 평활 등을 통하여  
계절성분  $S_t$ 를 분해하여 제거

## 2. 확률적 계절성

$(1 - B^d)S_t = X_t$ 를 만족시키는  
확률과정(이때,  $X_t$ 는 정상적 확률과정)

**SARIMA 모형**

계절성을 가지는 시계열

순수 SARIMA

승법 SARIMA

## 순수 SARIMA

시계열이 순수하게 계절형일 경우 때 적합할 수 있는 모형

$$\text{ARIMA}(P, D, Q)_s$$

$$\Phi(B^s)(1 - B^s)^D Z_t = \delta + \Theta(B^s)u_t \quad \text{혹은} \quad \Phi(B^s)(1 - B^s)^D Z_t = \Theta(B^s)\varepsilon_t$$

$$\Phi(B^s) = 1 - \Phi_1 B^s - \Phi_2 B^{2s} - \dots - \Phi_P B^{Ps}$$

$$\Theta(B^s) = 1 - \Theta_1 B^s - \Theta_2 B^{2s} - \dots - \Theta_Q B^{Qs}$$

- ☑ 현재의 관측치를 계절성을 고려하여  $Z_{t-s}, Z_{t-2s}, \dots$ 들로 설명
- ☑ 해당 주기 관측치는 P개를 고려하며, 해당 주기 오차항은 Q개를 고려
- ☑ 오차  $\varepsilon_t$ 는 백색잡음, D번 계절차분



계절성을 가지는 시계열

순수 SARIMA

승법 SARIMA

## 순수 SARIMA

- ✓ 비계절 요소에 대한 부분을 전혀 고려하지 않기에, **사용이 제한적**
- ✓ 오차가 백색잡음이므로, 계절주기에 해당되지 않는 시차의 **ACF는 0**



[ ARIMA(1, 0, 0)<sub>12</sub> ACF ][ ARIMA(1, 0, 0)<sub>12</sub> PACF ]

계절성을 가지는 시계열

순수 SARIMA

승법 SARIMA

## 순수 SARIMA – ACF, PACF

[ ARIMA(0, 0, 1)<sub>12</sub> ACF ][ ARIMA(0, 0, 1)<sub>12</sub> PACF ]

- ✓ ARMA 모형의 ACF와 PACF와 비슷함
- ✓ 단, **계절주기 차수에서만** 자기상관성을 가짐

계절성을 가지는 시계열

순수 SARIMA

승법 SARIMA

## 승법 SARIMA

$$Y_{j+12t} - \Phi_1 Y_{j+12(t-1)} - \cdots - \Phi_P Y_{j+12(t-P)} = U_{j+12t} + \Theta_1 U_{j+12(t-1)} + \cdots + \Theta_Q U_{j+12(t-Q)}$$

$$\Phi(B^{12})Y_t = \Theta(B^{12})U_t, \quad U_t \sim WN(0, \sigma^2)$$



$U_t$  가 백색잡음이 아니라 ARMA 모형을 따를 수도 있음!

$$U_t \sim ARMA(p, q)$$

$$\phi(B)U_t = \theta(B)\varepsilon_t, \quad U_t = \phi(B)^{-1}\theta(B)\varepsilon_t$$

$$\Phi(B^s)Y_t = \Theta(B^s)\phi(B)^{-1}\theta(B)\varepsilon_t$$

계절성을 가지는 시계열

순수 SARIMA

승법 SARIMA

SARIMA



순수 SARIMA / 승법 SARIMA의 오차항

$$\phi(B)U_t = \theta(B)\varepsilon_t, \quad U_t = \phi(B)^{-1}\theta(B)\varepsilon_t$$

$$\Phi(B^S)Y_t = \Theta(B^S)\phi(B)^{-1}\theta(B)\varepsilon_t$$

$$U_t \sim WN(0, \sigma^2)$$

$$\Phi(B^{12})Y_t = \Theta(B^{12})\underline{U_t}$$

순수 SARIMA 차분, D번 계절차분을 마친 상태의 시계열이라면,

$$Y_t = (1 - B)^d(1 - B^S)^D Z_t$$

$$U_t \sim ARMA(p, q)$$

$$\Phi(B^{12})Y_t = \Theta(B^{12})\underline{\phi(B)^{-1}\theta(B)\varepsilon_t}$$

승법 SARIMA

$$\phi(B)\Phi(B^{12})(1 - B)^d(1 - B^S)^D Z_t = \theta(B)\Theta(B^{12})\varepsilon_t$$

계절성을 가지는 시계열

순수 SARIMA

승법 SARIMA

## 승법 SARIMA

$$U_t \sim ARMA(p, q)$$

$$\phi(B)U_t = \theta(B)\varepsilon_t,$$

$$U_t = \phi(B)^{-1}\theta(B)\varepsilon_t$$

$$\Phi(B^s)Y_t = \Theta(B^s)\phi(B)^{-1}\theta(B)\varepsilon_t$$

$Y_t$ 가  $d$ 번 차분,  $D$ 번 계절차분을 마친 상태의 시계열이라면,

$$Y_t = (1 - B)^d(1 - B^s)^D Z_t$$



$$\phi(B)\Phi(B^{12})(1 - B)^d(1 - B^s)^D Z_t = \theta(B)\Theta(B^{12})\varepsilon_t$$

계절성을 가지는 시계열

순수 SARIMA

승법 SARIMA

## 승법 SARIMA

순수 SARIMA와 다르게, 승법 SARIMA는 비계절적 요소를 고려하는 모형  
순수 SARIMA모형의 오차가 ARIMA를 따름

$$ARIMA(P, D, Q)_s \text{ \& } U_t \sim ARIMA(p, d, q)$$

순수SARIMA에 ARIMA가 곱하기로 붙어서 ‘승법’이라는 용어 사용

$$SARIMA(p, d, q)(P, D, Q)_s$$

$$\phi(B)\Phi(B^s)(1-B)^d(1-B^s)^D Z_t = \theta(B)\Theta(B^s)\varepsilon_t$$

$$\Phi(B^s) = 1 - \Phi_1 B^s - \Phi_2 B^{2s} - \dots - \Phi_P B^{Ps}, \Theta(B^s) = 1 - \Theta_1 B^s - \Theta_2 B^{2s} - \dots - \Theta_Q B^{Qs}$$

$$\phi(B) = 1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p, \theta(B) = 1 - \theta_1 B - \theta_2 B^2 - \dots - \theta_q B^q$$



계절성을 가지는 시계열

순수 SARIMA

승법 SARIMA

## 승법 SARIMA

$$ARIMA(p, d, q)(P, D, Q)_s$$

$$\phi(B)\Phi(B^s)(1-B)^d(1-B^s)^D Z_t = \theta(B)\Theta(B^s)\varepsilon_t$$

비계절적 요소 고려

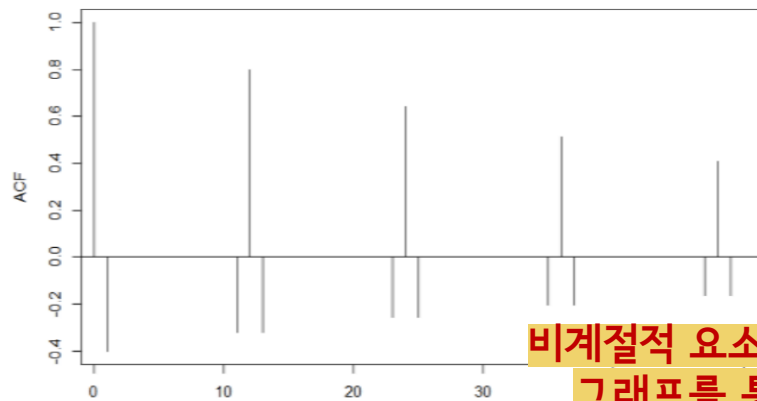
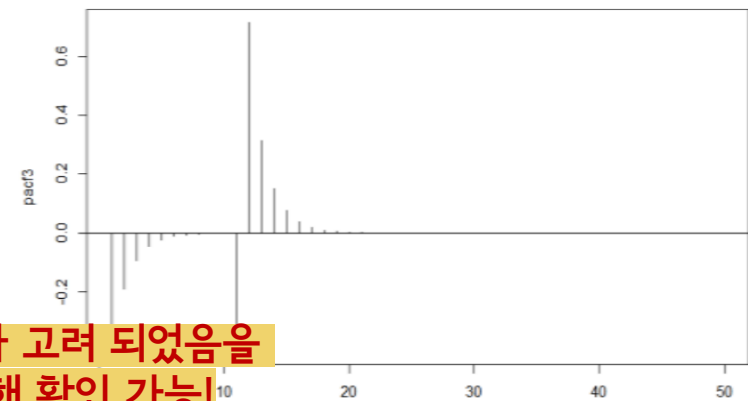
- ☑ 계절성과 추세를 고려한 모형
- ☑ ARIMA 모형처럼 예측시점과 가까운 과거 자료를 이용할 뿐만 아니라, 원자료의 주기적 특성을 반영하여 그 이전 주기의 자료를 추가적으로 활용
- ☑ 순수SARIMA보다 비계절 모형과 혼합된 모형이 모수 절약의 원칙에 따라 더 자주 사용됨

계절성을 가지는 시계열



순수 SARIMA

승법 SARIMA

## 승법 SARIMA – ACF, PACF

[ ARIMA(0,0,1)(1,0,0)<sub>12</sub> ACF ][ ARIMA(0,0,1)(1,0,0)<sub>12</sub> PACF ]

비계절적 요소가 고려 되었음을  
그래프를 통해 확인 가능!

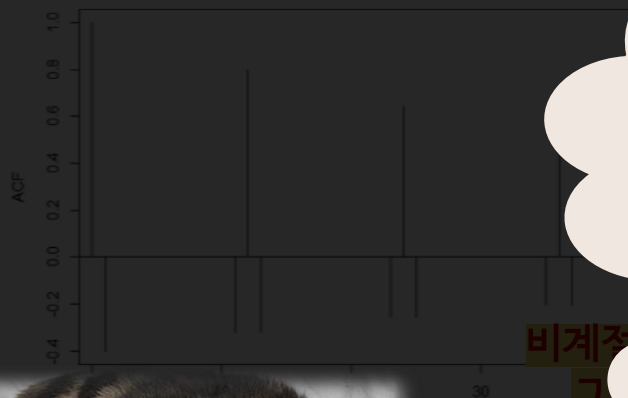
[ ARIMA(1,0,1)(0,0,1)<sub>12</sub> ACF ][ ARIMA(1,0,0)(0,0,1)<sub>12</sub> PACF ]

계절성을 가지는 시계열

순수 SARIMA

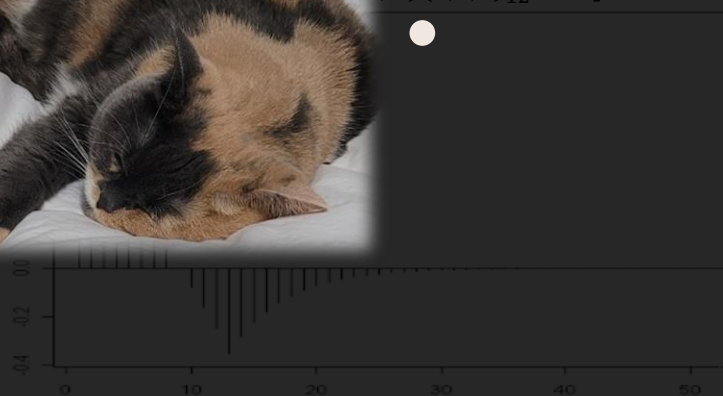
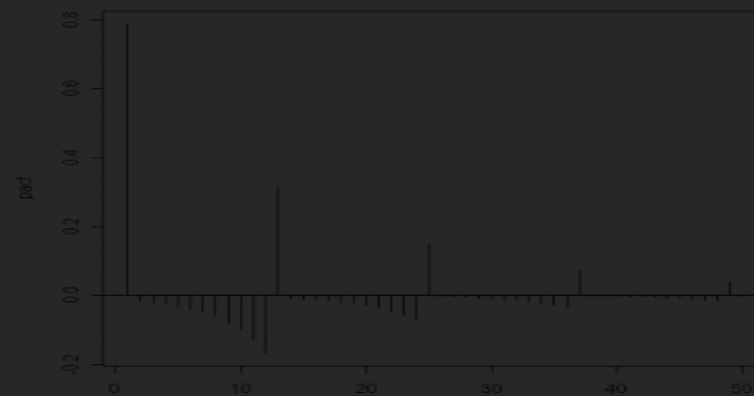
승법 SARIMA

## 승법 SARIMA – ACF, PACF

[ SARIMA(0,0,1)(1,0,0)<sub>12</sub> ACF ]

어떻게  
확인하는데요..??!

비계절적 요소가 고려  
그를 통해 확인 가능!

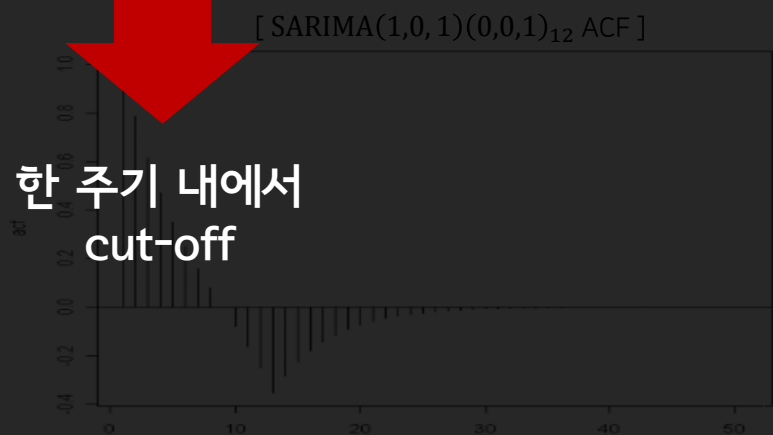
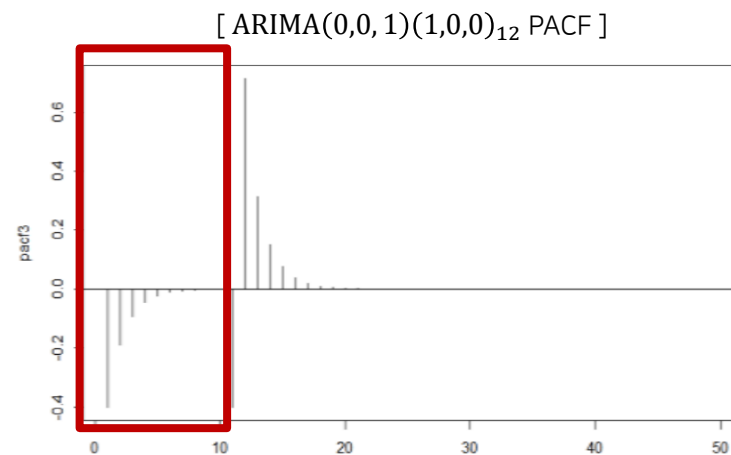
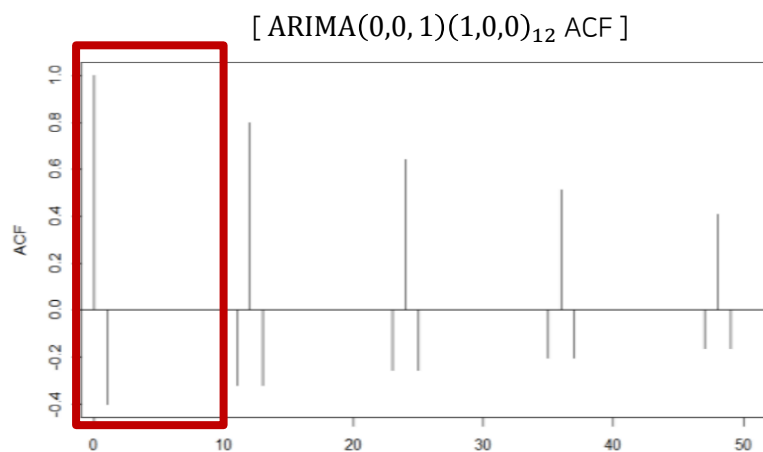
[ SARIMA(0,1)(0,0,1)<sub>12</sub> ACF ][ SARIMA(1,0,0)(0,0,1)<sub>12</sub> PACF ]

계절성을 가지는 시계열

순수 SARIMA

승법 SARIMA

## 승법 SARIMA – ACF, PACF


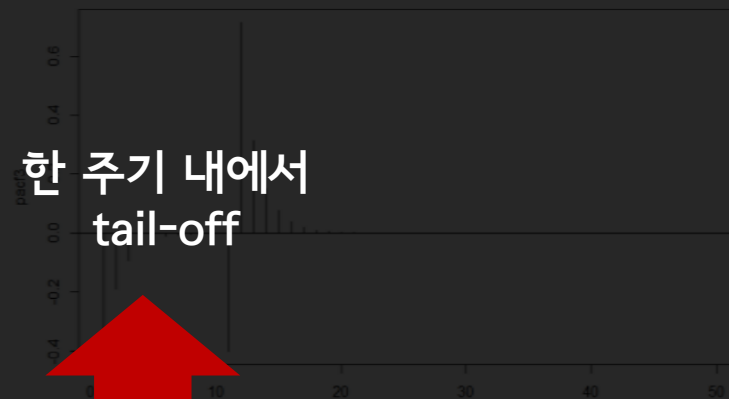




계절성을 가지는 시계열

순수 SARIMA

승법 SARIMA

## 승법 SARIMA – ACF, PACF

[ SARIMA(0,0,1)(1,0,0)<sub>12</sub> ACF ][ SARIMA(0,0,1)(1,0,0)<sub>12</sub> PACF ][ ARIMA(1,0,1)(0,0,1)<sub>12</sub> ACF ][ ARIMA(1,0,0)(0,0,1)<sub>12</sub> PACF ]

계절성을 가지는 시계열

순수 SARIMA

승법 SARIMA

승법 SARIMA

## 순수 SARIMA

$$ARIMA(P, D, Q)_s$$

$$\phi(B)\Phi(B^s)(1-B)^d(1-B^s)^D Z_t = \theta(B)\Theta(B^s)\varepsilon_t$$

$$\begin{aligned} \Phi(B^s)(1-B^s)^D Z_t \\ = \Theta(B^s)u_t \end{aligned}$$

✓ 계절성과 추세를 고려한 모형

✓ ARIMA 모형처럼 예측시점과 가까운 과거 자료를 이용할 뿐만 아니라, 원자료의 주기적 비계절적 요소를 고려하지 않음

✓ 순수SARIMA보다 비계절 모형과 혼합된 모형이 모수절약의 원칙에 따라 더 자주 사용됨

## 승법 SARIMA

$$SARIMA(p, d, q)(P, D, Q)_s$$

$$\begin{aligned} \phi(B)\Phi(B^s)(1-B)^d(1-B^s)^D Z_t \\ = \theta(B)\Theta(B^s)\varepsilon_t \end{aligned}$$

오차항  $u_t \sim ARIMA(p, d, q)$   
비계절적 요소를 고려함

4

ARFIMA

모형의 필요성

ARFIMA

ARFIMA 모형의 적합

ARFIMA

ARFIMA모형은 왜 필요할까?

ARFIMA

VS

AR

MA

ARMA


ARIMA



## 모형의 필요성

ARFIMA

ARFIMA 모형의 적합



기존의 모형들은 ACF 모양이  
기하급수적으로 감소

→ 단기억 확률과정

정상성을 만족하지만 ACF가 0으로  
느리게 수렴하는 시계열 자료에는  
좋은 적합이 아님

AR  
MA  
ARMA  
ARIMA


모형의 필요성

ARFIMA

ARFIMA 모형의 적합

ARFIMA

ARFIMA



MA

그 한계점을 보완한 모형이 **ARFIMA!**

ARFIMA 모형의 ACF는

0으로 느리게 수렴

→ 장기억 확률과정

모형의 필요성

ARFIMA

ARFIMA 모형의 적합

## ARFIMA

Auto Regressive Fractionally Integrated Moving Average  
유리수

ARIMA

 $d$  : 양의 정수

VS

ARFIMA

 $0 < d < \frac{1}{2}$

## ARFIMA

Auto Regressive Fractionally Integrated Moving Average

$$\text{ARFIMA}(p, d, q) : \phi(B)(1 - B)^d(Z_t - \mu) = \theta(B)\varepsilon_t, \text{ 이때 } 0 < d < \frac{1}{2}$$

$$\begin{aligned} \Rightarrow & (1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p) (1 - B)^d Z_t \\ &= (1 - \theta_1 B - \theta_2 B^2 - \dots - \theta_q B^q) \varepsilon_t \end{aligned}$$

모형의 필요성

ARFIMA

ARFIMA 모형의 적합

## ARFIMA

Auto Regressive Fractionally Integrated Moving Average

$$\text{ARFIMA}(p, d, q) : \phi(B)(1 - B)^d(Z_t - \mu) = \theta(B)\varepsilon_t, \text{ 이때 } 0 < d < \frac{1}{2}$$



$$(1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p)(1 - B)^d Z_t$$

1. 장기간 동안의 시계열 종속성 결정  $\varepsilon_t$
2. -0.5에서 0일 경우 자기상관함수가 0이 되는 문제 발생

## ARFIMA

장기억 확률과정 (long memory process)

$$\text{자기 상관 함수 } \rho(k) \sim Ck^{2d-1}, k \rightarrow \infty \text{ (단, } C > 0)$$

- ACF 합이 무한대로 발산.
- ACF가 0으로 빠르게 수렴하지 않음.

## ARFIMA 모형의 적합

### ARFIMA모형의 적합

- ARFIMA에서  $d$ 는 최소제곱법, 최대우도추정법으로 찾을 수 있음.
- 이후 ARMA모형과 비슷하게 나머지 모수를 추정.
- R에선 `arfima()` 함수를 사용할 수 있음.

## ARFIMA

*#arfima 함수에 데이터만 입력하면 알아서 찾아준다!*

```
sun = sunspots
arfima(sun)
```

```
##
## Call:
##   arfima(y = sun) AR 차수: 1   MA 차수: 2
##
## Coefficients:
##           d      ar.ar1      ma.ma1      ma.ma2
## 0.24676848 0.97439271 0.64294637 0.08996052
```

d값

ARFIMA(1, 0.2468, 2) 적합



# 5

이분산 시계열 모형

모형의 필요성

ARCH

GARCH

## 이분산 시계열 모형의 필요성

ARIMA와 같은  
전통적 시계열 모형




- 평균부분의 움직임에 초점을 맞춤.
- 등분산성을 가정.

모형의 필요성

ARCH

GARCH

ARCH



10일(현지 시간) 뉴욕 증시에서 테슬라 주가는 전날 대비 8.97% 오른 1025.05달러로 장을 마쳤다. 이는 종가 기준 테슬라의 사상 최고치다. / 그래프=김은실 디자이너.

금융관련 재무시계열 모형은 **불확실성을 의미하는 분산부분에**  
관심이 있고, 분산이 과거자료에 의존




**전통적 시계열 모형은 좋은 적합이 아니다!**

모형의 필요성

ARCH

GARCH

## 이분산 시계열 모형의 필요성



- 변동성 집중 현상 : 한번 큰 값을 기록하면 상당시간 동안 큰 상태로 지속된 후 다시 작은 값들이 상당기간동안 지속되는 현상.
- 변동성 집중 현상은 분산에 자기상관성이 존재함을 보여줌.

모형의 필요성

ARCH

GARCH

ARCH

## 이분산 시계열 모형의 필요성



따라서 **이분산 시계열 모형**이 필요!



- 변동성 집중 현상 : 한번 큰 값을 기록하면 상당시간 동안 큰 상태로 지속된 후 다시 작은 값들이 상당기간동안 지속되는 현상.
- 변동성 집중 현상은 분산에 자기상관성이 존재함을 보여준다.

모형의 필요성

ARCH

GARCH

## ARCH

자기회귀 조건부 이분산 모형

= **A**uto **R**egressive **C**onditional **H**eteroskedasticity

변동성을 설명하기 위한 비선형 모델

현재 시점의  
오차항 변동성

← 설명O

과거 시점의  
오차항 제공

모형의 필요성

ARCH

GARCH

## ARCH

ARCH(p): t시점의 오차항의 변동성을 p시점 전의  
오차항들의 제곱으로 설명하는 모형



모형의 필요성

ARCH


GARCH

## ARCH

ARCH(p): t시점의 오차항의 변동성을 p시점 전의  
오차항들의 제곱으로 설명하는 모형

[ ARCH(1) ]

$$\alpha_1 \varepsilon_{t-1}^2 + \alpha_0 = \sigma_t^2$$





모형의 필요성

ARCH


GARCH

## ARCH

ARCH(p): t시점의 오차항의 변동성을 p시점 전의  
오차항들의 제곱으로 설명하는 모형

[ ARCH(2) ]

$$\alpha_2 \varepsilon_{t-2}^2 + \alpha_1 \varepsilon_{t-1}^2 + \alpha_0 = \sigma_t^2$$



모형의 필요성

ARCH


GARCH

## ARCH

ARCH(p): t시점의 오차항의 변동성을 p시점 전의  
오차항들의 제곱으로 설명하는 모형

[ ARCH(p) ]

$$\alpha_p \varepsilon_{t-p}^2 + \dots + \alpha_2 \varepsilon_{t-2}^2 + \alpha_1 \varepsilon_{t-1}^2 + \alpha_0 = \sigma_t^2$$



모형의 필요성

ARCH

GARCH

## ARCH

[ 표현:  $\varepsilon_t \sim \text{ARCH}(p)$  ]

$$\{v_t\} \sim \text{i.i.d.} N(0,1)$$

$$\alpha_0 \geq 0, \alpha_j \geq 0, j = 1, \dots, p$$

$$\varepsilon_t = \sigma_t \cdot v_t$$

$$\sigma_t^2 = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2 + \alpha_2 \varepsilon_{t-2}^2 + \dots + \alpha_p \varepsilon_{t-p}^2$$

t시점의 오차항의 변동성을



p시점 전의 오차항들의 제공으로 설명

모형의 필요성

ARCH

GARCH

## ARCH

$$\text{ARCH}(1) : \varepsilon_t = \sigma_t \cdot v_t, \sigma_t^2 = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2$$

$$\varepsilon_t^2 = \sigma_t^2 \cdot v_t^2$$

$$= (\alpha_0 + \alpha_1 \varepsilon_{t-1}^2) \cdot v_t^2$$

$$= (\alpha_0 + \alpha_1 (\sigma_{t-1}^2 \cdot v_{t-1}^2)) \cdot v_t^2$$

재귀적으로  
계산해보면

$$\begin{aligned} & \dots \\ & = \alpha_0 \sum_{j=1}^n \alpha_1^j v_t^2 v_{t-1}^2 \cdots v_{t-j}^2 + \alpha_1^{n+1} v_t^2 \cdots v_{t-n}^2 \end{aligned}$$

모형의 필요성

ARCH

GARCH

## ARCH

ARCH(1) :  $\varepsilon_t = \sigma_t \cdot v_t$  [ ARCH(1) ]  $\sigma_t^2 = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2$

$$\varepsilon_t^2 = \alpha_0 \sum_{j=1}^n \alpha_1^j v_t^2 v_{t-1}^2 \cdots v_{t-j}^2 + \alpha_1^{n+1} v_t^2 \cdots v_{t-n}^2$$

$$= (\alpha_0 + \alpha_1 \varepsilon_{t-1}^2) \cdot v_t^2$$



$\varepsilon_t$  가  $v_t$  의 비선형적 형태  
따라서 ARCH는 비선형 모델!

$$= \alpha_0 \sum_{j=0}^n \alpha_1^j v_t^2 v_{t-1}^2 \cdots v_{t-j}^2 + \alpha_1^{n+1} v_t^2 \cdots v_{t-n}^2$$

모형의 필요성

ARCH

GARCH

## ARCH

## ARCH모형의 검정

귀무가설:  $H_0: \alpha_1 = \alpha_2 = \dots = \alpha_k = 0$

- LM(largrange multiplier) 검정: **검정통계량**  $n \cdot R_{\varepsilon}^2$  은 점근적으로  $\chi^2(p)$ 를 따른다는 성질을 활용하여 검정.
- Ljung-Box Q 검정 : ARCH(p) 모형에서  $\varepsilon_t^2$  가 AR(p)모형을 따름을 이용

모형의 필요성

ARCH

GARCH

## [ Ljung Box 검정 ]

```
Box.test(apple_ret_num^2, lag=4, type="Ljung")
```

ARCH(4)

```
##
```

```
## Box-Ljung test
```

```
##
```

```
- LM ## data: apple_ret_num^2
```

```
n * ## X-squared = 161.84, df = 4, p-value < 2.2e-16
```

- Ljung-Box Q 검정 : ARCH(p) 모형에서  $\varepsilon_t^2$  가 AR(p)모형을 따름을 이용

귀무가설 기각  
→ ARCH모형이 유의하다!

모형의 필요성

ARCH

GARCH

ARCH

## ARCH모형의 문제점

$$\sigma_t^2 = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2 + \alpha_2 \varepsilon_{t-2}^2 + \dots + \alpha_p \varepsilon_{t-p}^2 + \dots$$

추정해야 할  
모수가 많음



- 추정량의 정확도가 떨어짐
- 비음조건(non-negative)을 만족하기 어려움



모형의 필요성

ARCH

GARCH

ARCH

ARCH모형의 문제점



추정해야 할 모수가 많아지는  
문제를 해결하려면?

$$\sigma_t^2 = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2 + \alpha_2 \varepsilon_{t-2}^2 + \dots + \alpha_p \varepsilon_{t-p}^2 + \dots$$


추정해야 할 모수가

추정량의 제한도가 떨어진다

일반화된 모형이 필요! → GARCH 모형

(음수인 (non-negative) 값을 갖기 어렵다.

모형의 필요성

ARCH

GARCH

GARCH

일반화 자기 회귀 이분산 모형

= Generalized Auto Regressive Conditional Heteroskedastic

ARCH 모형을 일반화한 모형

현재 시점의  
오차항 변동성

설명

과거 시점의 오차항 제공  
과거 시점의 변동성

모형의 필요성

ARCH

GARCH

## GARCH

[ 표현:  $\varepsilon_t \sim \text{GARCH}(p,q)$  ]

$$\varepsilon_t = \sigma_t \cdot v_t$$

$$\begin{aligned} \{v_t\} &\sim \text{i.i.d.} N(0,1) \\ \alpha_0 &\geq 0, \alpha_j \geq 0, \beta_j \geq 0 \\ j &= 1, \dots, p \end{aligned}$$

$$\begin{aligned} \sigma_t^2 &= \alpha_0 + \alpha_1 \varepsilon_{t-1}^2 + \alpha_2 \varepsilon_{t-2}^2 + \dots + \alpha_p \varepsilon_{t-p}^2 + \\ &\quad \beta_1 \sigma_{t-1}^2 + \beta_2 \sigma_{t-2}^2 + \dots + \beta_p \sigma_{t-q}^2 \\ &= \alpha_0 + \sum_{i=1}^p \alpha_i \varepsilon_{t-i}^2 + \sum_{j=1}^q \beta_j \sigma_{t-j}^2 \end{aligned}$$

모형의 필요성

ARCH

GARCH

GARCH

[ 표현:  $\varepsilon_t \sim \text{GARCH}(p, q)$  ]

$$\varepsilon_t = \sigma_t \cdot v_t$$

$\{v_t\}$  : 가우시안 백색잡음  
 $\alpha_0 \geq 0, \alpha_j \geq 0, \beta_j \geq 0$   
 $j = 1, \dots, p$

$$\sigma_t^2 = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2 + \alpha_2 \varepsilon_{t-2}^2 + \dots + \alpha_p \varepsilon_{t-p}^2 + \text{ARCH}$$

**ARCH**  $\beta_1 \sigma_{t-1}^2 + \beta_2 \sigma_{t-2}^2 + \dots + \beta_q \sigma_{t-q}^2$  추가된 부분 추가된 부분

$$\sigma_t^2 = \alpha_0 + \sum_{i=1}^p \alpha_i \varepsilon_{t-i}^2 + \sum_{j=1}^q \beta_j \sigma_{t-j}^2$$

모형의 필요성

ARCH

GARCH

GARCH

[ 표현:  $\varepsilon_t \sim G$ 

$$\varepsilon_t = \sigma_t \cdot v_t$$

$$\sigma_t^2 = \alpha_0 + \alpha_1 \varepsilon_t^2 + \alpha_2 \varepsilon_{t-1}^2 + \dots + \alpha_p \varepsilon_{t-p}^2 + \beta_1 \sigma_{t-1}^2 + \beta_2 \sigma_{t-2}^2 + \dots + \beta_p \sigma_{t-p}^2$$



**GARCH 모형은 왜 ARCH 모형보다**

**추정해야 할 모수가 적을까?**



**GARCH(1,1)의 예시로 알아보자!**

모형의 필요성

ARCH

GARCH

## GARCH

$$[\varepsilon_t \sim \text{GARCH}(1,1)]$$

$$\varepsilon_t = \sigma_t \cdot v_t$$

$$\sigma_t^2 = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2 + \beta_1 \sigma_{t-1}^2$$

$$(1 - \beta_1) \sigma_t^2 = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2$$

$$\sigma_t^2 = \frac{\alpha_0}{(1 - \beta_1)} + \frac{\alpha_1}{(1 - \beta_1)} \varepsilon_{t-1}^2$$

$$= \frac{\alpha_0}{(1 - \beta_1)} + \alpha_1 \sum_{j=1}^{\infty} \beta_1^{j-1} \varepsilon_{t-j}^2$$

$$\begin{aligned} \{v_t\} &\sim \text{i.i.d.} N(0,1) \\ \alpha_0 &\geq 0, \alpha_j \geq 0, \beta_j \geq 0 \\ j &= 1, \dots, p \end{aligned}$$

모형의 필요성

ARCH

GARCH

GARCH

[  $\varepsilon_t \sim \text{GARCH}(1,1)$  ]

$$\varepsilon_t = \sigma_t \cdot v_t$$

$$\sigma_t^2 = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2 + \beta_1 \sigma_{t-1}^2$$

$$(1 - \beta_1) \sigma_t^2 = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2$$

$$\sigma_t^2 = \frac{\alpha_0}{(1 - \beta_1)} + \frac{\alpha_1}{(1 - \beta_1)} \varepsilon_{t-1}^2$$

$$\sigma_t^2 = \frac{\alpha_0}{(1 - \beta_1)} + \alpha_1 \sum_{j=1}^{\infty} \beta_1^{j-1} \varepsilon_{t-j}^2 \rightarrow \text{ARCH}(\infty)$$

$$\begin{aligned} \{v_t\} &\sim \text{i.i.d.} N(0,1) \\ \alpha_0 &\geq 0, \alpha_j \geq 0, \beta_j \geq 0 \\ j &= 1, \dots, p \end{aligned}$$

모형의 필요성

ARCH

GARCH

GARCH

[  $\varepsilon_t \sim \text{GARCH}(1,1)$  ] $\{v_t\}$  : 가우시안 백색잡음 $\alpha_0 \geq 0, \alpha_j \geq 0, \beta_j \geq 0$  $\varepsilon_t = v_t$  ARCH에서 많은 모수들을 추정해야 했던 문제를 해결! $\sigma_t^2 = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2 + \beta_1 \sigma_{t-1}^2$  $(1 - \beta L) \sigma_t^2 = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2$  $\text{GARCH}(1, 1) = \text{ARCH}(\infty)$ 

$$\sigma_t^2 = \frac{\alpha_0}{(1 - \beta L)} + \frac{\alpha_1}{(1 - \beta L)} \varepsilon_{t-1}^2$$

$$= \frac{\alpha_0}{(1 - \beta L)} + \alpha \sum_{j=1}^{\infty} \beta^{j-1} \varepsilon_{t-j}^2$$





**THANK YOU**

